

Evidence-Verified Agentic Execution in a Local Linux Environment

Martin Stamenov

Локален Linux agent · истражувачки прототип

17 септември 2026

Exit code 0

≠

постигната

цел

Launcher
може да
успее без
видлив
прозорец.

Browser request Model-
може да generated
заврши на success не
друга страница. е доказ.

Model output is not evidence

Planner
предлага.
Executor
дејствува.

Verifier ја
набљудува
состојбата.

Task done
бара проверен
goal condition.

Четири прашања

RQ1 · Дали verification открива false- success claims?	RQ2 · Може ли planning да остане capability- constrained?	RQ3 · Дали evidence преживува failures и restarts?	RQ4 · Како reproducibly се споредува retrieval?
---	---	--	---

Од цел до доказ

Проверка на реалната датотека

Секој исход останува видлив

Capability name + validated arguments

Registry	Нема	Нема	Valid JSON
→ schema model-	автоматско	не значи	
→ policy	generated deletion,	semantic	
→	shell killing или	correctness.	
executor.	execution. installation.		

Две мерки, различни прашања

H_raw = False	Raw claims и	Verified
reported claims =	финалните	impossible task
rate – reported	user-visible	може да значи
verified success	пораки се	правилно
rate AND unmet	различни.	одбивање.

372 trials ·

исторически

run

31 tasks B0 launcher · 60 control 52/52
× 4 B1 keywords trials → 8 eligible
variants · B2 model · contaminated controls
× 3 A ARIES excluded correctly
repeats UNMET

Verification ≠ подбор planner

Variant	Verified / n	H_raw	False claims
B0	57 / 68	+11.8 pp	8
B1	45 / 67	0.0 pp	0
B2	60 / 67	+6.0 pp	4
A	60 / 67	+6.0 pp	4

**Null
result
останува
null
result**

A – B2 Двете
= 0.0 варијанти
pp произведуваат
verified4 raw false
rate. claims.

Verifier ги
идентификува
независна
user study
за
финалното
reporting.

THREATS
TO
VALIDITY

Што не

смеете да

заклучиме

Fixed variant	Само 3–4	Една	3 од 4
order; cold-	clean app	машина,	model false
browser bias	trials по	една	claims: ист
за B0.	варијанта.	session,	weather
		qwen2.5:7b.task.	

11/11
full ·
7/7
core

Историски
passing demo
artifacts од 17
септември.

Претходни
full
attempts:
1/11, 9/11,
10/11.

Missing-file
task мора да
fail-не за test
да помине.

Engineering
acceptance ≠
scientific
superiority.

15/20

⁴

подобрувања

Exact

20 developer-

paired labelled cases;

Development

evidence, не

→

· 0 регресии

test: $p =$ нема held-out

statistical

19/20

0.125

validation.

superiority.

Bounded multi-step execution

4/4

сценарија

• реален

local

model

File	SystemBrowserMissing- 10	После 0/4,
done · done · done ·	file	planner0/4, 2/4, 3/4,
2	1 step · 2 steps failed,	calls · 3/4:
steps · 4.166 s ·	test	36,039 development
10.734	10.853 PASS ·	native evidence
s	s	1 step · tokens
	4.154 s	

Што

на вистина

се случи?

Freeze code

и

independently

labelled

benchmark.

RandomizedCold vs

order;

dedicated

desktop

session.

Learned:

success,

tokens,

steps,

latency.

Секое

success

тврдење

мора да

има

проверлив

доказ.